

Детекція об'єктів на термальних зображеннях засобами YOLOv8s

Куцик Владислав

1 Вступ

Термальні камери реєструють інфрачервоне випромінювання об'єктів незалежно від видимого освітлення, що робить їх незамінними для систем підтримки водіння (ADAS), нічного відеоспостереження та аварійно-рятувальних операцій [3]. На відміну від RGB-знімків, теплові зображення є монохромними, мають меншу чіткість меж і нетипові візуальні сигнатури об'єктів, тому стандартні підходи комп'ютерного зору потребують спеціального адаптування. Задачу формалізують як детекцію об'єктів:

$$f_{\theta} : I \mapsto \{(\hat{\mathbf{b}}_j, \hat{c}_j, s_j)\}_{j=1}^M,$$

де $\hat{\mathbf{b}}_j = (x_j, y_j, w_j, h_j)$ — обмежувальна рамка, $\hat{c}_j \in \{1, 2, 3\}$ — мітка класу (*person*, *car*, *bike*), $s_j \in [0, 1]$ — достовірність. Набір FLIR ADAS [3] містить понад 10 000 анотованих термальних кадрів 640×512 пікс. Як детектор обрано YOLOv8s [2] — модель, що за один прохід мережі виробляє всі прогнозовані рамки, класи та достовірності.

2 Препроцесинг теплових зображень

Вхідний кадр $I \in \mathbb{R}^{H \times W}$ (8-бітний рівень сірого) послідовно проходить п'ять перетворень.

1. Min-Max нормалізація рівномірно розтягує гістограму яскравості на весь діапазон $[0, 255]$, усуваючи різницю між кадрами з різними налаштуваннями чутливості камери:

$$s_1[p] = \frac{I[p] - I_{\min}}{I_{\max} - I_{\min} + \varepsilon} \cdot 255. \quad (1)$$

2. Двобічна фільтрація (Bilateral filter) видаляє шум мікроболометрового масиву, зберігаючи теплові межі об'єктів завдяки одночасному врахуванню просторової та інтенсивнісної близькості пікселів:

$$s_2[p] = \frac{1}{W_p} \sum_{q \in \Omega} s_1[q] G_{\sigma_s}(\|p - q\|) G_{\sigma_r}(|s_1[p] - s_1[q]|), \quad (2)$$

де G_{σ_s} — просторовий гаусіан ($d = 5$, $\sigma_s = 15$), G_{σ_r} — діапазонний гаусіан ($\sigma_r = 15$), W_p — нормувальний коефіцієнт.

3. CLAHE (Contrast Limited Adaptive Histogram Equalization) підсилює локальний контраст у плитках 8×8 пікс. з обмеженням підсилення $\text{clip} = 2.0$. Це виявляє слабкі теплові сигнатури велосипедистів, що зливаються з тлом дороги.

4. Unsharp masking загострює теплові межі об'єктів:

$$s_4 = \text{clip}((1 + \alpha) s_3 - \alpha \cdot G_{\sigma} * s_3, 0, 255), \quad (3)$$

де $\alpha = 0.6$, G_{σ} — гаусіан 5×5 пікс.

5. Gray $\rightarrow$ 3-канальний BGR: канал рівня сірого реплікується тричі для сумісності зі стандартним RGB-входом YOLOv8, при цьому зайва конвертація BGR $\rightarrow$ RGB не потрібна, оскільки всі три канали рівні між собою.

Результат кожного кроку проілюстровано на рис. 1: нормалізація «розтягує» гістограму, двобічна фільтрація знижує зернистість, CLAHE виявляє деталі, а unsharp mask чіткіше окреслює силует об'єктів.



Рис. 1: Ключові кроки препроцесингу одного кадру: оригінал (зліва зверху), після двобічної фільтрації, після CLAHE, після unsharp masking (справа знизу).

3 Архітектура YOLOv8s та детекційна голова

Модель складається з трьох блоків. **Backbone** (CSPDarknet + C2f) витягує карти ознак C_3, C_4, C_5 з кроком 8, 16 та 32 пікс. відповідно. **Neck** (FPN) формує збагачені карти P_3, P_4, P_5 шляхом поєднання рівнів:

$$P_l = \text{Conv}_{1 \times 1}(C_l) \oplus \text{Up}(P_{l+1}), \quad l \in \{3, 4, 5\}, \quad (4)$$

де $\text{Up}(\cdot)$ — білінійне збільшення, $\oplus$ — поелементне додавання. Карта P_3 виявляє дрібні об'єкти (велосипедисти), P_5 — великі (автомобілі).

3.1 Роз'єднана без'якірна голова

Голова YOLOv8 є без'якірною (не потребує апріорних шаблонів форм рамок) і роз'єднаною: класифікація та регресія виконуються незалежними гілками (рис. 2).




Рис. 2: Роз'єднана без'якірна голова YOLOv8: дві незалежні гілки на кожній карті P_l ($l \in \{3, 4, 5\}$). K — к-сть класів, $R=16$ — к-сть бінів розподілу.

Гілка класифікації для кожної позиції (i, j) виробляє K незалежних значень із sigmoid-активацією:

$$p_k = \sigma(z_k^{\text{cls}}), \quad k = 1, \dots, K. \quad (5)$$

Гілка регресії кодує кожну з чотирьох меж рамки (l, t, r, b) як розподіл ймовірностей по $R+1=17$ дискретних значеннях (Distribution Focal Loss). Очікувана відстань до межі:

$$\hat{d} = \sum_{n=0}^R n \cdot \text{softmax}(\mathbf{z}^{\text{reg}})_n. \quad (6)$$

Розподільне кодування дає точнішу локалізацію, ніж пряма регресія одного числа. Роз'єднання гілок зменшує взаємне заважання між завданнями класифікації та регресії.

4 Функції втрат та метрики якості

Навчання YOLOv8 керує адитивна функція [2]:

$$\mathcal{L} = \lambda_{\text{box}} \mathcal{L}_{\text{CIoU}} + \lambda_{\text{cls}} \mathcal{L}_{\text{cls}} + \lambda_{\text{dfl}} \mathcal{L}_{\text{DFL}}. \quad (7)$$

Complete IoU loss штрафує водночас площу перекриття, відстань між центрами та неузгодженість пропорцій сторін:

$$\mathcal{L}_{\text{CIoU}} = 1 - \text{IoU} + \frac{\rho^2(\mathbf{b}, \mathbf{b}^{gt})}{c^2} + \alpha v, \quad (8)$$

де $v = \frac{4}{\pi^2} \left(\arctan \frac{w^{gt}}{h^{gt}} - \arctan \frac{w}{h} \right)^2$ — штраф за пропорції, c — діагональ охоплюючого прямокутника.

Бінарна крос-ентропія для класифікації (K незалежних бінарних задач):

$$\mathcal{L}_{\text{cls}} = - \sum_{k=1}^K [y_k \log \hat{p}_k + (1-y_k) \log (1-\hat{p}_k)]. \quad (9)$$

Distribution Focal Loss для точної регресії меж рамки:

$$\mathcal{L}_{\text{DFL}} = -[(y_{i+1}-y) \log S_i + (y-y_i) \log S_{i+1}], \quad (10)$$

де $y \in [y_i, y_{i+1}]$ — справжня межа, S_i — ймовірність i -го інтервалу.

Метрики. Основні — mAP@50 та mAP@50:95. Рамка є TP, якщо $\text{IoU} \geq \tau$ з еталоном того самого класу:

$$P = \frac{TP}{TP+FP}, \quad R = \frac{TP}{TP+FN}, \quad \text{AP}_k = \int_0^1 P(R) dR.$$

Через класову незбалансованість також визначають $F_1 = \frac{2PR}{P+R}$ та MCC:

$$\text{MCC} = \frac{TP \cdot TN - FP \cdot FN}{\sqrt{(TP+FP)(TP+FN)(TN+FP)(TN+FN)}}, \quad (11)$$

стійкий до дисбалансу між класами.

5 Додаткові техніки навчання

5.1 Оверсемплінг класу *bike*

Клас *bike* суттєво недопредставлений ($N_b \ll N_p, N_c$). Зображення з велосипедистами дублюються з динамічним коефіцієнтом:

$$f = \min \left(6, \left\lfloor \frac{0.4 \cdot \max(N_p, N_c)}{N_b} \right\rfloor \right), \quad (12)$$

що підводить частку *bike* до ~40% від найчастішого класу без ризику перепоповнення диска.

5.2 Однофазне навчання: warmup та диференційний LR

Замість двофазного заморожування/розморожування backbone застосовано єдину 20-епохову фазу з двома захисними механізмами.

Warmup (5 еп.): $\eta(t) = \eta_0 \cdot t/T_w$ — лінійне зростання кроку навчання від нуля запобігає руйнуванню COCO-ваг на старті.

Диференційний LR: backbone (шари 0–9) оновлюється у 10 разів повільніше, ніж голова:

$$\eta_{\text{bb}} = \frac{\eta_0}{10} = 10^{-5}, \quad \eta_{\text{head}} = \eta_0 = 10^{-4}. \quad (13)$$

Реалізовано через callback `on_train_start`, що розбиває парам groups оптимізатора на backbone/head і синхронізує `scheduler.base_lrs`. Cosine-decay до $\eta_f=10^{-6}$; аугментація — виключно горизонтальне дзеркалення (`flip_lr=0.5`), яке не порушує теплову семантику сцени.

6 Результати

Після 20 епох навчання на валідаційній вибірці досягнуто mAP@50>0.83 та $F_1(\text{macro})>0.90$ для класів *person* та *car*. Клас *bike* показав нижчий AP внаслідок об'єктивно меншої кількості навчальних прикладів навіть після оверсемплінгу. На рис. 3 показано успішну одночасну детекцію кількох класів на одному нічному термальному кадрі при порозі достовірності $s=0.35$: модель коректно розставила рамки навколо автомобіля та людей різних розмірів.



Рис. 3: Мультикласова детекція на одному термальному кадрі: *car* та *person* різних розмірів, нічні умови (поріг достовірності = 0.35).

Література

- [1] Redmon J., Divvala S., Girshick R., Farhadi A. You Only Look Once: Unified, Real-Time Object Detection. *Proc. IEEE CVPR*, 2016. arxiv.org/abs/1506.02640.
- [2] Jocher G., Chaurasia A., Qiu J. Ultralytics YOLOv8. 2023. docs.ultralytics.com/models/yolov8.
- [3] FLIR Systems. Free ADAS Thermal Dataset for Algorithm Training. 2019. flir.com/oem/adas/adas-dataset-form/.